Date de rendu : 21/03/2025

Traitement d'images niveau 1

Classifications supervisées

Faculté de géographie et d'aménagement
Université de Strasbourg

Observation de la Terre et Géomatique

Théo LIEGEON

Master 1 Observation de la Terre et Géomatique

Table des matières

Introduction 1
Objectif : 1
Description de la zone d'étude : 1
Les données : 1
Problématique : 1
Premières classifications avec les données de base (RVB +PIR) 2
Méthodologie 2
Prétraitement : 2
Classifications : 3
Résultat 5
Affiner la classification 6
Assemblage des attributs exogènes : 8
Classification finale : 9
Conclusion : 10

Table des figures

Figure 1 : Diagramme de traitement 4
Figure 2 : Classification pixel RVB + PIR 5
Figure 3 : Classification objet RVB + PIR 5
Figure 4 : Matrices de classification objet/pixel RVB + PIR 6
Figure 5 : Classification objet RVB + PIR + Entropie PIR 7
Figure 6 : Classification objet RVB + PIR + NDVI 7
Figure 7 : Matrices de classification objet RVB + PIR + ENTROPIE ET NDVI 7
Figure 9 : Matrices de classification objet RVB + PIR + MNE 8
Figure 8 : Classification objet RVB + PIR + MNE 8
Figure 10 : Classification objet RVB + PIR + MNE + NDVI 8
Figure 11 : Matrices de classification objet RVB + PIR + MNE + NDVI 8
Figure 12 : Classification objet RVB + PIR + MNE + NDV et classes finales 9
Figure 13 : Matrices de classification objet RVB + PIR + MNE + NDVI et classes finales 9

Introduction

Objectif :

L'objectif de cette étude est de classifier une zone précise à partir d'une image multispectrale. Nous utiliserons plusieurs méthodes de classification et différentes données annexes afin d'avoir la meilleure classification possible aussi bien visuellement que statistiquement. Le but final étant la recherche de la classification la plus satisfaisante en modifiant les typologies ainsi que les attributs exogènes en entrée.

Description de la zone d'étude :

Notre zone d'étude est située à Vendenheim au Nord de Strasbourg en Bas-Rhin (67). Elle représente une emprise d'1km x 1 km. Cette zone est visuellement composée en majorité par des espaces urbanisés. On peut aussi y observer la présence de végétation aussi bien des arbres que du sol herbacé ou encore agricole. Un canal passe au Nord – Est de l'emprise du raster.

Les données :

Nous allons effectuer nos classifications à partir de différentes données mises en libre-service. Elles se composent d'une part d'une image multispectrale ayant une bande Rouge, Verte, Bleu et Proche Infrarouge (PIR) fournie par les satellites Pléiades. D'autre part, nous avons aussi à disposition des MNE de végétation et de bâtiments que nous pourrons rajouter à la donnée initiale afin de peaufiner la classification de celle-ci.

A l'origine situé à près de 800Km d'altitude, le satellite va effectuer des mesures multispectrales. (Bleu : 430–550 nm, Vert : 490–610 nm Rouge : 600–720 nm, PIR : 750–950 nm). Originellement acquises avec une précision de 70 cm, elles seront rééchantillonnées à 50 cm puis géoréférencé. Nous pourrons donc espérer une classification assez pointue en Lambert 93.

Problématique :

Comment les différentes techniques de traitement d'image, la structuration des classes et la diversité des types de données contribuent-elles à améliorer la précision et l'efficacité d'une classification ?

Premières classifications avec les données de base (RVB +PIR)

Méthodologie

Prétraitement :

Afin d'effectuer les classifications, nous devons, dans un premier temps, affecter des groupements de pixels ayant des paramètres similaires. Nous utiliserons le traitement *LargeScaleMeanShift* du plugin *Orfeo ToolBox* (OTB). Celui-ci va nous générer une couche vectrice composée d'objets regroupant les pixels se ressemblants.

Cette couche sera composée des champs ayant les valeurs moyennes des pixels pour les bandes de l'image ainsi que leurs variances.

On peut la paramétrer à sa guise sur cette étape selon nos exigences. On peut modifier les valeurs :

- *Spatial Radius* : 5 (valeur par défaut que j'ai décidé de garder). Elle correspond à l'application d'un filtre sur 5 pixels autour du pixel cible afin d'obtenir des valeurs similaires.
- *Range Radius* : 10, cette valeur permet de déterminer plus ou moins le lissage lors du traitement. Une valeur élevée va lisser les données (15) contrairement à une valeur faible qui va laisser du bruits (5). Mon choix me parait correct. Il permet d'avoir un bon compromis.
- *Minimum Segment Size* : 200, cette valeur correspond au minimum de pixels possible qui seront fusionnés dans un objet. Une valeur faible va augmenter le bruit (pour la classification objet) ainsi que la durée de traitement. Une valeur à 200 permet d'avoir un bon compromis sur la précision tout en lissant le résultat pour la classification objets.

Par la suite nous devons déterminer les classes que nous utiliserons pour la classification de l'image multispectrale.

Dans un premier temps il a été intéressant d'avoir des classes assez précises par rapport au milieu.

5 Classes ont pu se démarquer, 1 : bâtis, 2 : route, 3 : herbacé, 4 : agricole, 5 : arbre, 6 : eau.

Après le choix de notre typologie, nous devons placer des points d'entrainement et de contrôles de manière à les disposés sur l'ensemble de l'image par rapport aux objets contenus dans la couche *LargeScaleMeanShift.*

J'ai donc opté pour 20 points d'entrainement et 10 points de contrôle pour chaque classe. Ils seront disposés de façon à être assez dispersés sur les entités *LargeScaleMeanShift* différentes. En effet, 2 points d'entrainement ou contrôle sur la même entité sont inutiles, et mettre un point d'entrainement au même endroit qu'un point de contrôle serait contre-productif.

Par la suite, nous allons joindre par localisation le champs « type » de la couche des points d'entrainement à la couche *LargeScaleMeanShift* et supprimer toutes les entités non jointes. Ainsi, une couche Shape est créée avec les objets surfaciques de *LargeScaleMeanShift* et les attributs de classe. La même chose sera effectuée pour les points de contrôle.

Classifications :

La prochaine étape consiste à l'entrainement d'un modèle pour la classification. Ces premières classifications vont me permettre de déterminer laquelle entre la classification Objet et Pixel pourrait correspond le mieux à mes attentes.

Ainsi, dans un premier temps, je vais entrainer un modèle pour une classification Objet.

La classification d'objet implique de regrouper les pixels en objets ou segments avant de les classifier. Cela signifie que vous identifiez d'abord des zones homogènes dans l'image, puis vous attribuez une classe à chaque objet en fonction de ses caractéristiques globales.

A l'aide de l'outil *TrainVectorsClassifer*, je vais renter l'image Pléiades puis les Shape polygone d'entrainement et le Shape polygone contrôle ainsi que le nom du champ des classes. Pour le choix de la méthode de classification, j'utiliserai toujours l'algorithme d'apprentissage supervisé *Random Forest*.

Cet algorithme fonctionne en combinant plusieurs arbres de décision pour améliorer la précision et la robustesse des prédictions, tout en minimisant le risque de surapprentissage.

Le fichier final est un format *.rf* qui permettra d'effectuer la classification.

La prochaine étape consiste à appliquer le modèle précédemment entrainé, sur le Shape *LargeScaleMeanShift* à l'aide de l'outil *VectorClassifer*. Le fichier en sortie étant un Shape avec de multiples entiers ayant les mêmes classes, il est nécessaire de les grouper par rapport à leurs classes puis de les rastériser.

Le résultat final est un *GeoTIFF* qu'il restera à présenter.

Par la suite, à l'aide de l'outil *ComputeConfusionMatrix*, la matrice nous sera fournie en comparant le Shape polygone contrôle à notre *GeoTIFF*.

Nous décidons aussi de lancer une classification Pixel sur le même principe de paramétrage qu'une classification Objet tout en échangeant l'outil *TrainVectorsClassifer* par *TrainImagesClassifer* et *VectorClassifier* par *ImageClassifier*.

La classification de pixels implique d'attribuer une classe à chaque pixel de l'image indépendamment des autres pixels. Chaque pixel est classé sur la base de ses propres caractéristiques spectrales ou texturales.

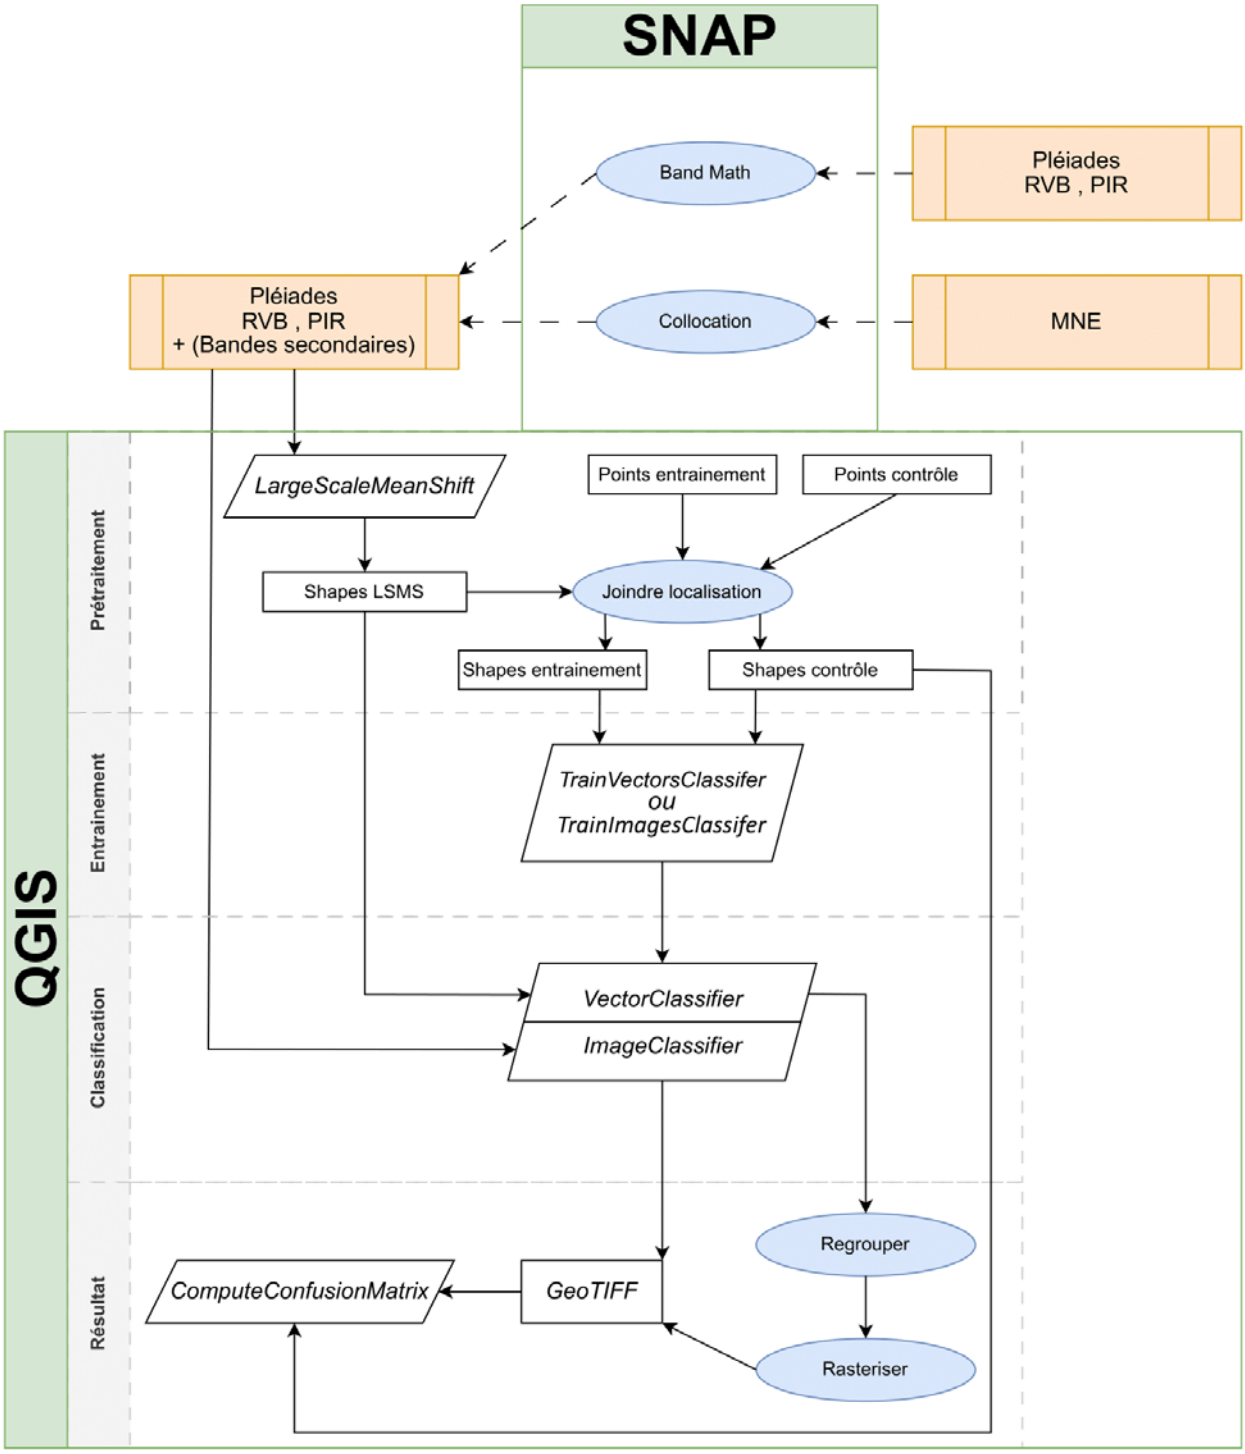

Figure 1 : Diagramme de traitement

Résultat

Visuellement, on observe que la classification objet semble beaucoup moins précise que le pixel, ainsi que plus lisse.

La classification pixel, par contre, semble beaucoup plus précise pour la végétation.

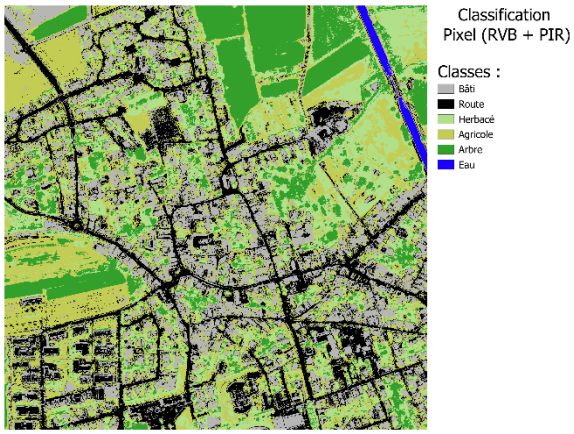

Figure 2 : Classification pixel RVB + PIR

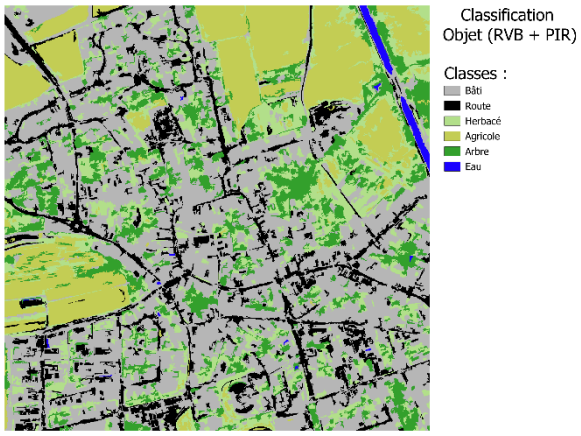

Figure 3 : Classification objet RVB + PIR

En comparant les matrices, on observe que la méthode objet est plus précise par rapport au rappel, à la précision, et au *F-score* sauf pour les bâtiments.

Précision : Mesure la fiabilité des prédictions positives.
Rappel : Mesure la capacité du modèle à détecter tous les cas positifs.
F-score : Combine les deux pour fournir une évaluation globale de la performance du modèle.

En résumé :

Réduction du bruit pour la méthode objets : Etant donné que nous générons des objets plus grands qu'un simple pixel.

Précision fine pour la méthode pixel : Offre une classification très précise au niveau des détails.

On observe néanmoins une certaine confusion entre :

- Les routes et les bâtiments
- L'ensemble des classes de végétation entre elles
- Les bâtiments avec l'ensembles des autres classes

RVB + PIR

Pixel	Bati	Route	Herbacé	Agricole	Arbre	Eau	Rappel
Bati	3018	204	43	14	0	0	**92,04**
Route	263	4122	0	202	0	0	**89,86**
Herbacé	22	312	2939	1235	16	0	**64,96**
Agricole	97	44	1435	17555	2025	0	**82,98**
Arbre	18	15	657	562	2998	0	**70,54**
Eau	648	13	0	8	1	3014	**81,81**
Précision	**74,23**	**87,52**	**57,92**	**89,68**	**59,48**	**100,00**	

F-score	82,18	88,67	61,24	86,20	64,54	90,00
F-score moyen	78,81					
Rappel moyen	78,14					
Précision moyenne	80,37					

Objet	Bati	Route	Herbacé	Agricole	Arbre	Eau	Rappel
Bati	3284	260	0	0	16	0	**92,25**
Route	336	4852	17	0	0	0	**93,22**
Herbacé	766	70	3399	726	35	0	**68,03**
Agricole	0	0	425	21630	14	0	**98,01**
Arbre	51	0	125	0	4579	0	**96,30**
Eau	966	23	0	0	0	2861	**74,31**
Précision	**60,78**	**93,22**	**85,70**	**96,75**	**98,60**	**100,00**	

F-score	73,28	93,22	75,85	97,38	97,44	85,26
F-score moyen	87,07					
Rappel moyen	89,18					
Précision moyenne	87,02					

Figure 4 : Matrices de classification objet/pixel RVB + PIR

La suite du dossier consistera ainsi à trouver d'autre attributs exogènes en entrée afin de réduire cette confusion. Nous aurions aussi pu modifier les paramètres des traitements ou encore nos classes, mais ils paraissent corrects pour notre dossier.

Affiner la classification

Etant donné les problèmes de confusion entre les classes de végétation elles-mêmes ainsi que les bâtiments, il a été décidé de relancer 2 classifications différentes avec une bande en plus à l'image à chaque fois. J'utiliserai la méthode objet pour la suite étant donné sa précision, mais aussi car les objets créés sont assez utiles dans ce contexte majoritairement urbain. Ils prennent les formes des bâtiments ou des zones.

Pour la première classification, nous rajouterons une bande entropie calculée sur SNAP à l'aide de la bande PIR (Band Math → -(band_4*log(band_4)/log(2)))

$$\boldsymbol{H(X) = -\sum_{i=1}^{n} P(xi) log2\mathrm{P(xi)}}$$

Cette bande entropie peut nous permettre de mieux distinguer les types de végétation ainsi que les points d'eau.

Pour la seconde classification, nous rajouterons une bande d'Indice de Végétation par Différence Normalisée (NDVI) calculée sur SNAP (Band Math → (band_4-band_3)/ (band_4-band_3)

$$\boldsymbol{NDWI = \frac{(PIR - R)}{(PIR + R)}}$$

Cette bande NDVI peut nous permettre d'observer la distribution et la densité de la végétation, les types de végétation ainsi que les points d'eau.

Par la suite, nous effectuons le même traitement que la classification objets précédente ainsi que les mêmes points de traitement et de contrôle (Tout en vérifiant s'ils ne sont pas dans une même entité étant donné que la couche *LargeScaleMeanShift* va se retrouver modifiée à cause de la 5ème bande.)

Visuellement, le résultat de la classification semble mieux avec une bande entropie PIR, notamment pour les routes et les bâtiments. On peut observer la même chose pour le NDVI, avec un lissage plus élevé.

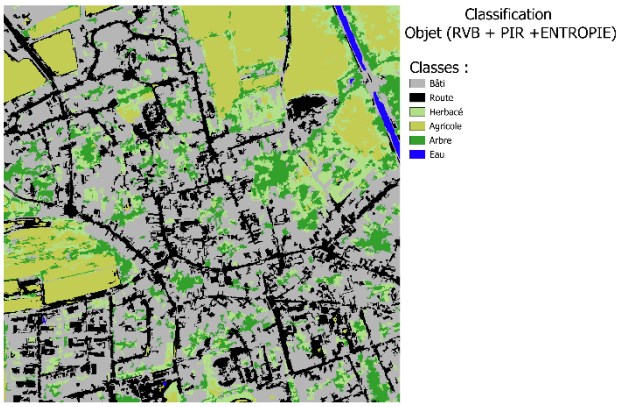

Figure 5 : Classification objet RVB + PIR + Entropie PIR

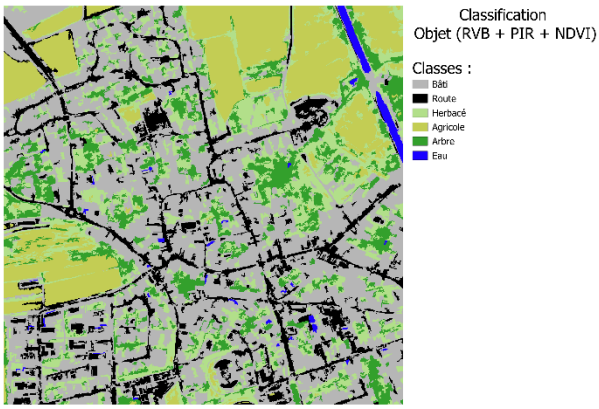

Figure 6 : Classification objet RVB + PIR + NDVI

Pour les matrices :

- Avec l'entropie, on observe que la seule classe à s'être améliorée est celle dite herbacé. A contrario, l'ensemble des autres classes se sont détériorées, particulièrement l'eau et les espaces urbanisés
- Avec le NDVI, on observe une amélioration de l'ensemble des classes, sauf les arbres qui se sont détériorés.

RVB + PIR +ENTROPIE PIR

Objet	Bati	Route	Herbacé	Agricole	Arbre	Eau	Rappel
Bati	3036	14	14	0	0	0	99,09
Route	1574	3370	0	0	0	0	68,16
Herbacé	560	446	3629	449	0	0	71,38
Agricole	0	0	207	4554	0	0	95,65
Arbre	110	0	214	0	3544	0	91,62
Eau	1277	8	7	0	0	1195	48,05
Précision	46,30	87,81	89,14	91,03	100,00	100,00	

F-score	63,11	76,75	79,28	93,28	95,63	64,91
F-score moyen	78,83					
Rappel moyen	85,71					
Précision moyenne	78,99					

RVB + PIR +NDVI

Objet	Bati	Route	Herbacé	Agricole	Arbre	Eau	Rappel
Bati	3475	30	55	0	0	0	97,61
Route	362	4809	21	0	0	0	92,62
Herbacé	786	0	3569	470	37	0	73,41
Agricole	0	0	8	21792	14	0	99,90
Arbre	25	0	661	0	4053	16	85,24
Eau	973	17	0	0	0	3523	78,06
Précision	61,82	99,03	82,73	97,89	98,76	99,55	

F-score	75,70	95,72	77,79	98,88	91,50	87,51
F-score moyen	87,85					
Rappel moyen	89,96					
Précision moyenne	87,81					

Figure 7 : Matrices de classification objet RVB + PIR + ENTROPIE ET NDVI

Ainsi, pour moi, seule la couche NDVI pourrait être utile pour les classifications finales, l'entropie étant de la même utilité mais beaucoup moins efficace.

Pour les problèmes de confusion entre les routes et les bâtiments, nous avons effectué une 3ème classification en rajoutant une bande MNE des bâtiments. Celle-ci a été rajoutée à l'image sur SNAP. Elle sera par la suite prétraitée sur QGIS afin de remplacer les valeurs NULL par -9999 (« NO DATA ») avant de suivre, elle-aussi, une classification objets.

Visuellement, cette classification a énormément lissé les classes. On arrive aussi à reconnaitre parfaitement les contours des routes ou des bâtiments qui ne semblent plus confondus entre eux.

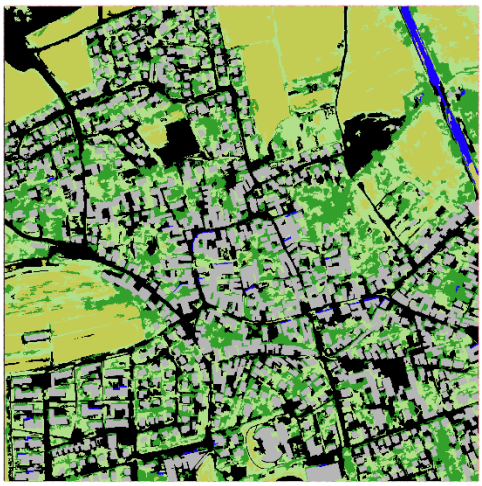

Figure 8 : Classification objet RVB + PIR + MNE

RVB + PIR + MNE bâtiments

Objet	Bati	Route	Herbacé	Agricole	Arbre	Eau	Rappel
Bati	2878	478	26	0	7	0	84,92
Route	43	5988	40	0	48	0	97,86
Herbacé	0	738	3186	735	55	0	67,59
Agricole	0	0	425	21630	14	0	98,01
Arbre	0	6	767	0	3751	0	82,91
Eau	0	15	0	2244	78	1877	44,54
Précision	98,53	82,88	71,69	87,89	94,89	100,00	

F-score	91,22	89,75	69,58	92,68	88,50	61,63
F-score moyen	82,23					
Rappel moyen	89,31					
Précision moyenne	79,31					

Figure 9 : Matrices de classification objet RVB + PIR + MNE

Pour la matrice, on observe que le *F-score* de la classe bâtiment a nettement augmenté au détriment des autres classes. Il serait probablement assez utile pour une classification finale avec d'autres attributs exogènes en entrée.

Assemblage des attributs exogènes :

Etant donné que la bande NDVI et le MNE bâti semblent permettre d'améliorer la classification dans des modelés indépendants et pour des classes différentes, il serait intéressant d'observer une classification à l'aide des bandes d'origine de l'image (RVB + PIR) plus la bande NDVI et MNE bâtis.

Après les différents traitements de la classification objets, nous pouvons observer sur la *GeoTIFF* final un très bon lissage. L'ensemble des classes est très bien défini et très reconnaissable.

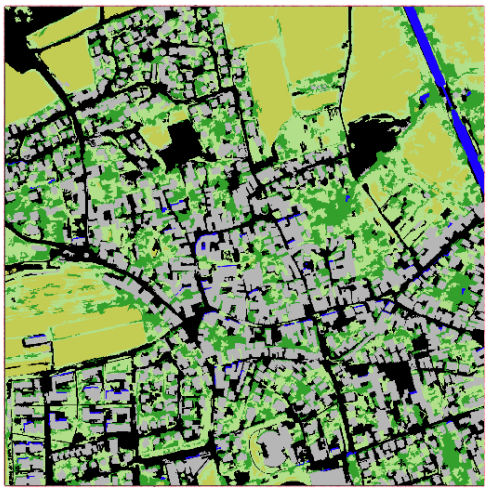

Figure 10 : Classification objet RVB + PIR + MNE + NDVI

RVB + PIR + MNE bâtiments + NDVI

Objet	Bati	Route	Herbacé	Agricole	Arbre	Eau	Rappel
Bati	2947	416	26	0	0	0	86,96
Route	200	5266	159	0	0	0	93,62
Herbacé	24	628	3518	395	15	0	76,81
Agricole	0	0	440	21374	0	0	97,98
Arbre	24	20	921	0	3543	16	78,32
Eau	6	82	3	0	31	4393	97,30
Précision	92,06	82,13	69,43	98,19	98,72	99,64	

F-score	89,44	87,50	72,93	98,08	87,34	98,45
F-score moyen	88,96					
Rappel moyen	90,03					
Précision moyenne	88,50					

Figure 11 : Matrices de classification objet RVB + PIR + MNE + NDVI

En comparant avec la vue de base, on observe que la classification est très fidèle à la réalité malgré des imprécisions.

Pour la matrice de confusion, on peut observer que le *F-score* des classes bâtiment, agricole et eau a très largement augmenté. Toutefois, les routes et les arbres ont diminué ainsi que les espaces herbacés.

Les couches attributs exogènes en entrée semblent assez précis. Il serait intéressant de modifier la nomenclature des classes.

Classification finale :

La dernière classification se fera sur les bandes RVB, PIR, NDVI et MNE étant donné les résultats précédents. Nous continuerons d'utiliser une classification objets mais en remodelant les classes. Ainsi aux vues de la dernière matrice, la classe herbacés était assez confondue avec l'ensemble des autres classes. Etant donné qu'elle est très proche de nature avec la classe agricole, Il a été décidé de les fusionner (donc modification des couches de contrôles et d'entrainement).

Après traitement, visuellement, le *GeoTIFF* est très ressemblant au précèdent. Nous avons un problème lié aux ombres des bâtiments qui sont confondu avec de l'eau comme sur l'ensemble des classifications précédents.

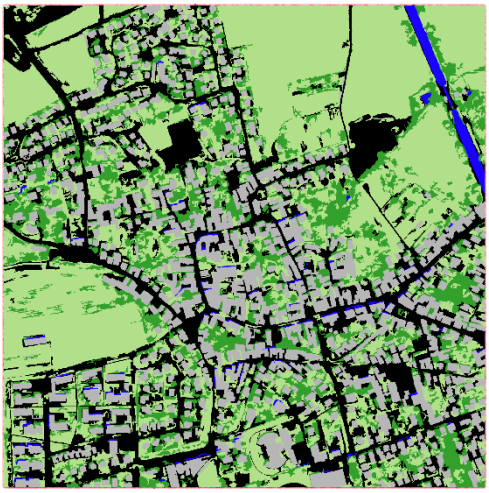

Figure 12 : Classification objet RVB + PIR + MNE + NDV et classes finales

RVB + PIR +MNE bâtiments + NDVI

Objet	Bati	Route	Terres Agricoles et Herbeuses	Arbre	Eau	Rappel
Bati	2953	425	11	0	0	87,13
Route	184	5282	159	0	0	93,90
Terres Agricoles et Herbeuses	24	549	25792	29	0	97,72
Arbre	0	20	926	3562	16	78,74
Eau	6	82	3	31	4393	97,30
Précision	93,24	83,08	95,91	98,34	99,64	

F-score	90,09	88,16	96,81	87,45	98,45

F-score moyen	92,19
Rappel moyen	94,04
Précision moyenne	90,96

Figure 13 : Matrices de classification objet RVB + PIR + MNE + NDVI et classes finales

Mais, pour la matrice, on observe que le *F-score* de la nouvelle classe a augmenté. Au final, les précisions et rappels semblent assez élevés ainsi que les *F-score.*

Cette classification semble donc suffisante avec un *F-score* moyen à 92,2, des rappels moyens et une précision moyenne supérieure aux autres.

Conclusion :

Avoir un objectif clair aurait permis un choix de bande plus précise, comme par exemple, effectuer une classification seulement du point de vue de la végétation. Ainsi nous aurions pu réduire le nombre d'attributs exogènes en entrée et limiter leurs répercutions les uns sur les autres.

La méthode aussi peut différer selon la volonté du résultat final. Un résultat plus précis mais avec plus de bruits aurait été possible avec la méthode pixel.

D'autre attributs auraient pu être rajoutés pour peaufiner la classification comme infrarouge à courte longueur d'onde (SWIR) pour l'eau ou encore une seconde image d'une autre période de l'année pour observer l'évolution des végétaux au risque d'alourdir les traitements, de les rendre plus longs et d'amener une certaine confrontation d'informations entre bandes.

Une classification multi-temporelle aurait probablement permis de corrigé l'ensemble des imprécisions liées à la végétation ainsi que les ombrages.

L'ensemble des entrainements ont été effectué avec la méthode Random Forest. D'autres auraient pu être utilisés comme Gradient Boosting Machines (GBM) ou Maximum Likelihood Classification (MLC).

Une semi-automatisation aurait aussi pu être développée à l'aide du modeleur QGIS. Malheureusement, étant donné que le plugin n'était pas assez stable, il était impossible d'automatiser le traitement de façon optimisée sur sa totalité.

Après avoir pris en compte les 2 méthodes de classification, la nomenclature des classes et les attributs exogènes en entrée, il est possible d'affirmer qu'une classification objets sur des bandes rouges, vert, bleu, PIR, NDVI et MNE bâtis avec 5 classes assez différentes semble assez précise pour cette zone d'étude et notre demande. Cette classification permet d'avoir un résultat convenable avec seulement 5 bandes en entré, ainsi qu'un temps de traitement le plus court possible.